

StudyGuard: ekspertski sistem za procjenu rizika od akademskog burnout-a kod studenata

Nikolina Petronić, SV 59/2022

Motivacija

Mentalno zdravlje studenata je oblast u kojoj se problemi često prepoznaju kasno. Studenti se uglavnom javljaju za pomoć tek kada simptomi značajno utiču na koncentraciju, kvalitet sna, društveni život i svakodnevno funkcionisanje. Jedan od problema koji se često javlja u akademskom okruženju jeste akademski burnout, odnosno stanje dugotrajnog iscrpljivanja usljed hroničnog akademskog opterećenja.

Burnout se ne javlja kao jedan izolovan simptom, već kao kombinacija faktora: hroničan umor, loš san, osjećaj preopterećenosti, pad motivacije, odlaganje obaveza, smanjena koncentracija i osjećaj slabije akademske efikasnosti. Upravo zbog toga nije dovoljno posmatrati samo jedan dnevni unos studenta, već je potrebno pratiti obrasce koji se razvijaju kroz vrijeme.

Svjetska zdravstvena organizacija (eng. World Health Organization, WHO) definiše burnout kao fenomen koji nastaje kao posljedica hroničnog stresa koji nije uspješno kontrolisan, a karakterišu ga iscrpljenost, mentalna distanca ili cinizam prema radu i smanjena efikasnost [\[1\]](#). WHO naglašava da burnout nije klasifikovan kao medicinska dijagnoza, već kao fenomen vezan za kontekst rada [\[1\]](#). U ovom projektu WHO definicija se koristi kao opšti okvir za razumijevanje burnout-a, dok se procjena u akademskom kontekstu zasniva na validiranim studentskim modelima i instrumentima kao što su MBI-SS, SBI i CBI-S.

Cilj projekta nije da sistem postavlja medicinsku dijagnozu niti da zamijeni psihologa, psihijatra ili savjetovalište. Cilj je razvoj ekspertskog sistema koji prepoznaje rane obrasce rizika i korisniku pruža objašnjivu preporuku: da obrati pažnju na san, smanji opterećenje, potraži podršku ili zakaže razgovor sa stručnim licem ako se rizičan obrazac nastavi.

Pregled problema

U oblasti mentalnog zdravlja postoje brojne aplikacije, kao što su Headspace, Calm, Woebot i Wysa, koje nude meditaciju, relaksaciju, praćenje raspoloženja ili chatbot podršku. Međutim,

takve aplikacije uglavnom nisu usmjerene na akademski burnout kao specifičan problem studenata, niti korisniku daju objašnjiv trag zaključivanja zasnovan na eksplicitno definisanim pravilima.

Pored opštih aplikacija za mentalno zdravlje, postoje validirani instrumenti za procjenu studentskog burnout-a, kao što su MBI-SS, SBI, CBI-S i noviji BAT-S [7]. Postoje i pojedina digitalna rješenja za procjenu burnout-a, npr. Burnout Assessment Tool platforma i BURNTES [8] aplikacija za ranu detekciju burnout-a kod učenika/studenata. Međutim, ova rješenja se prvenstveno oslanjaju na upitnike, samoprocjenu ili prikaz rezultata, dok predloženi sistem akademski burnout posmatra kao problem ekspertskog zaključivanja: znanje se eksplicitno modeluje kroz pravila, obrasci se prate kroz vrijeme, a korisnik dobija objašnjenje zbog čega je određeni nivo rizika dodijeljen.

Postojeća rješenja imaju nekoliko ograničenja:

- opšte aplikacije za mentalno zdravlje uglavnom nude opšte intervencije, ali nisu specifično usmjerene na akademski burnout.
- validirani upitnici i digitalni alati za procjenu burnout-a mogu izmjeriti prisustvo ili intenzitet simptoma, ali sami po sebi nisu rule-based ekspertski sistemi i ne prikazuju lanac zaključivanja kroz činjenice, indikatore, vremenske obrasce i konačnu procjenu rizika.
- akademski burnout se ne prepoznaje na osnovu jednog unosa, već kroz ponavljanje obrazaca kao što su loš san, visok stres, pad motivacije, izbjegavanje obaveza i izostanak oporavka. Zato je pogodno koristiti rule-based zaključivanje i CEP.

StudyGuard zato kombinuje validirane dimenzije akademskog burnout-a sa pravilima koja prate promjene kroz vrijeme. Na taj način rezultat nije samo numerički skor iz upitnika, već objašnjiva procjena rizika zasnovana na indikatorima, vremenskim obrascima i akademskom kontekstu studenta.

Naučna osnova projekta

Projekat se zasniva na validiranim modelima akademskog burnout-a.

Maslach Burnout Inventory – Student Survey (MBI-SS) definiše tri ključne dimenzije: emocionalnu iscrpljenost, cinizam i akademsku efikasnost [2]. School Burnout Inventory (SBI) koristi sličnu strukturu kroz iscrpljenost, cinizam i osjećaj neadekvatnosti [3]. Copenhagen Burnout Inventory – Student Version (CBI-S) omogućava kvantifikaciju intenziteta burnout simptoma [4].

U ovom projektu ovi instrumenti se ne koriste kao dijagnostički testovi, već kao osnova za organizaciju baze znanja. Sistem prati tri dimenzije:

- akademsku iscrpljenost,
- cinizam/distancu prema studijama,
- smanjenu akademsku efikasnost.

Na osnovu kombinacije ovih dimenzija i njihovog razvoja kroz vrijeme, sistem procjenjuje rizik od burnout-a.

Pored tri osnovne dimenzije akademskog burnout-a, sistem uzima u obzir i zaštitne i pogoršavajuće faktore. U zaštitne faktore spadaju percipirana socijalna podrška porodice, prijatelja, kolega, profesora ili mentora [5], kao i adaptivne *coping* strategije, npr. planiranje, traženje pomoći i aktivno rješavanje problema [6]. U pogoršavajuće faktore spadaju maladaptivne strategije, npr. izbjegavanje obaveza, poricanje problema i pasivno odlaganje. Ovi faktori se ne koriste kao posebne dimenzije burnout-a, već kao elementi koji mogu pojačati ili ublažiti procijenjeni rizik.

Metodologija rada

Sistem je implementiran kao rule-based ekspertski sistem korišćenjem Drools-a. Backend je implementiran u Java/Spring Boot aplikaciji, pravila su izdvojena u KJAR modul, domenski model je izdvojen u poseban Maven modul, a korisnički/demo interfejs je implementiran kao Angular frontend aplikacija.

Projekat je organizovan kroz sljedeće cjeline:

- **model** – domenski model, činjenice, događaji, indikatori, obrasci, faktori, rizici i izlazni objekti;
- **kjar** – Drools pravila, query-ji, CEP pravila i rule template fajlovi;
- **service** – Spring Boot REST API i integracija sa Drools engine-om;
- **frontend** – Angular klijentska aplikacija za unos podataka i demonstraciju scenarija;
- **docs** – dokumentacija, dijagram i JSON demo scenariji.

Sistem se pokreće preko REST endpoint-a:

POST /api/assessment

Ulaz u sistem je **AssessmentRequest**, a izlaz je **RiskAssessment**.

Za demonstraciju sistema pripremljeni su JSON testni scenariji u folderu docs/demo-scenarios, kao i frontend prepared examples koji omogućavaju brzo pokretanje low risk, template, negative trend i severe burnout scenarija.

Sistem konceptualno predviđa dva tipa korisnika:

Student

Student unosi dnevne podatke o snu, stresu, umoru, motivaciji, akademskom opterećenju, efikasnosti, oporavku, podršci i coping strategiji. Na osnovu tih unosa sistem procjenjuje rizik i vraća objašnjenje, dominantne dimenzije i preporuke.

Savjetnik/administrator sistema

Savjetnik/administrator predstavlja ulogu za održavanje baze znanja i konfiguracionih pragova. U ovoj implementaciji ne postoji poseban admin panel, već se pragovi održavaju kroz rule template podatke. Iz tih podataka se generiše fajl `10_profile_thresholds.drl`, koji zatim postaje dio Drools baze znanja. Na taj način se pragovi mogu mijenjati kontrolisano.

Forward chaining

Forward chaining se koristi kao osnovni mehanizam zaključivanja u sistemu. Ovaj pristup je vođen podacima, gdje sistem polazi od unesenih činjenica i kroz pravila dolazi do zaključaka.

U ovom sistemu forward chaining se realizuje kroz više nivoa zaključivanja:

1. Ulazne činjenice

U radnu memoriju se ubacuju **StudentContext** i lista **DailyCheckInEvent** događaja.

2. Pragovi po profilu i akademskom periodu

Na osnovu **StudentContext** činjenice, template-generated pravilo ubacuje odgovarajući **ThresholdProfile**.

3. **ScoreAdjustment** činjenice

Pravila analiziraju dnevne unose i ubacuju **ScoreAdjustment** činjenice. Na primjer:

- kratak san povećava skor iscrpljenosti,
- visok stres povećava skor iscrpljenosti,
- niska motivacija povećava skor cinizma,
- subjektivna efikasnost utiče na skor akademske efikasnosti.

4. Parcijalni skorovi

Korišćenjem **accumulate** funkcije sistem iz više **ScoreAdjustment** činjenica formira **ExhaustionScore**, **CynicismScore** i **EfficacyScore**.

5. Indikatori

Na osnovu skorova i **ThresholdProfile** činjenice formiraju se **ExhaustionIndicator**, **CynicismIndicator** i **ReducedEfficacyIndicator**.

6. CEP obrasci i faktori

Posebna pravila formiraju vremenske obrasce i zaštitne/pogoršavajuće faktore, npr. **SustainedStressPattern**, **LowRecoveryPattern**, **AvoidancePattern**, **ProtectiveSupportFactor**, **MaladaptiveCopingFactor**.

7. Rizik i finalna procjena

Kombinovanjem indikatora, obrazaca, trendova i faktora sistem formira rizike. Na kraju se formira **RiskAssessment**, koji sadrži nivo rizika, dominantne dimenzije, aktivirane dokaze, preporuke i objašnjenje.

Lanac zaključivanja:

DailyCheckInEvent ----> **ScoreAdjustment** ----> **Score** ----> **Indicator** ---->
Pattern/Factor/Risk ----> **RiskAssessment**

CEP pravila

CEP se koristi za obrasce kroz vrijeme, ne za jednokratne unose. To je naročito važno jer burnout nastaje postepeno.

Numerički pragovi u sistemu predstavljaju operative pragove za implementaciju ekspertskog sistema. Oni neće biti predstavljeni kao univerzalne kliničke granice, već kao konfigurabilne vrijednosti izvedene iz literature, domenskih konsultacija i potreba demonstracije sistema. Glavna stručna logika sistema nije u pojedinačnom pragu, već u kombinovanju validiranih dimenzija burnout-a i njihovog vremenskog razvoja.

Primjeri CEP pravila:

Obrasci iscrpljenosti i opterećenja:

- Ako student ima najmanje 4 dana sna kraćeg od 6 sati u posljednjih 7 dana, ubacuje se **SustainedPoorSleepPattern**.
- Ako postoje najmanje 3 dnevna unosa u posljednjih 7 dana i ako je prosječan stres veći ili jednak pragu visokog stresa, ubacuje se **SustainedStressPattern**.
- Ako student ima slab oporavak najmanje 3 dana u posljednjih 7 dana, ubacuje se **LowRecoveryPattern**.

Obrasci distanciranja:

- Ako student ima najmanje 2 propuštene obaveze u posljednjih 10 dana, ubacuje se **AvoidancePattern**.

- Ako student ima motivaciju manju ili jednaku 3 najmanje 4 dana u posljednjih 7 dana, ubacuje se RepeatedLowMotivationPattern.

Obrasci akademskog uticaja:

- Ako student najmanje 3 dana u posljednjih 7 dana prijavljuje nisku akademsku efikasnost, ubacuje se AcademicGoalDeviationPattern.

Trendovi:

- Ako se ExhaustionScore povećava ili EfficacyScore smanjuje kroz najmanje 3 uzastopna unosa, sistem ubacuje NegativeTrend.

Ovi CEP obrasci se kasnije koriste u forward chaining pravilima za procjenu rizika. Takođe se prevode u evidence činjenice koje backward chaining query-ji koriste pri provjeri da li postoji obrazac konzistentan sa akademskim burnout-om.

U implementaciji se koriste time-based sliding windows i accumulate funkcija, prvenstveno za brojanje događaja i računanje prosječnih vrijednosti u posmatranom vremenskom periodu.

Backward chaining

Backward chaining se koristi kada sistem treba da odgovori na konkretno pitanje:

“Da li kod studenta postoji obrazac rizika konzistentan sa akademskim burnout-om?”

Za razliku od forward chaining-a, koji polazi od dnevnih unosa i izvodi skorove, indikatore, obrasce i preporuke, backward chaining polazi od cilja hasAcademicBurnoutPattern(studentId). Query-ji provjeravaju da li u radnoj memoriji postoje izvedene činjenice koje su prethodno nastale forward chaining i CEP pravilima.

U implementaciji se backward chaining realizuje preko evidence graph pristupa. Prvo se konkretne izvedene činjenice prevode u EvidenceNode činjenice. Na primjer, ako postoje ExhaustionIndicator, CynicismIndicator, ReducedEfficacyIndicator, SustainedStressPattern, SustainedPoorSleepPattern, LowRecoveryPattern, AvoidancePattern, AcademicGoalDeviationPattern ili NegativeTrend, sistem za njih kreira odgovarajuće EvidenceNode činjenice za konkretnog studenta.

Nakon toga se formiraju grupni evidence čvorovi. CoreBurnoutEvidence nastaje kada postoje sve tri osnovne burnout dimenzije: ExhaustionIndicator, CynicismIndicator i ReducedEfficacyIndicator. ChronicityEvidence nastaje kada postoje vremenski obrasci koji pokazuju da problem nije zasnovan na jednom unosu, npr. kombinacija

SustainedPoorSleepPattern i SustainedStressPattern ili kombinacija lošeg sna i slabog oporavka. AcademicImpactEvidence nastaje kada postoji dokaz da se obrazac odražava na akademsko ponašanje ili efikasnost, npr. AvoidancePattern, AcademicGoalDeviationPattern ili NegativeTrend.

Veze između dokaza modeluju se pomoću EvidenceRelation činjenica. One opisuju hijerarhiju dokaza, npr. da CoreBurnoutEvidence, ChronicityEvidence i AcademicImpactEvidence podržavaju viši pojam BurnoutEvidence, a da BurnoutEvidence dalje podržava AcademicBurnoutPattern.

Rekurzivni query reachesEvidence provjerava da li jedan evidence čvor direktno ili indirektno vodi ka višem cilju u evidence graph-u. Query supportsEvidence dodatno provjerava da li konkretan student ima određeni evidence čvor i da li taj čvor podržava traženi cilj.

Glavni query hasAcademicBurnoutPattern(studentId) vraća pozitivan rezultat samo ako za studenta postoje CoreBurnoutEvidence, ChronicityEvidence i AcademicImpactEvidence, i ako sva tri preko evidence graph-a podržavaju AcademicBurnoutPattern.

Servisni sloj nakon izvršavanja pravila poziva:

```
getQueryResults("hasAcademicBurnoutPattern", studentId)
```

Rezultat query-ja se upisuje u finalni RiskAssessment kroz polje hasAcademicBurnoutPattern. Backward chaining ne mijenja nivo rizika, već služi kao dodatna objašnjiva provjera da li aktivirani dokazi zajedno čine obrazac konzistentan sa akademskim burnout-om.

Template pravila

Template pravila se koriste za generisanje pragova po tipu studenta i akademskom periodu. Time se sistem prilagođava različitim akademskim situacijama, bez ručnog pisanja velikog broja sličnih DRL pravila.

U implementaciji se koristi template fajl profile-thresholds.drt. Generator ThresholdTemplateGenerator iz tabelarnih podataka generiše konkretna DRL pravila u fajlu 10_profile_thresholds.drl. Svako generisano pravilo odgovara jednoj kombinaciji profila studenta i akademskog perioda. Primjer pragova za određene profile i akademske periode:

Profil studenta/akadem	Akademski period	Minimalan broj	Prag visokog stresa	Prag niske efikasnosti	Maksimalan broj
------------------------	------------------	----------------	---------------------	------------------------	-----------------

ski kontekst		sati sna			propuštenih obaveza
DEFAULT	REGULAR_CLASSES	6	7	4	2
WORKING_STUDENT	MIDTERM_WEEK	5	8	4	3
FINAL_YEAR	EXAM_PERIOD	6	7	5	2
FRESHMAN	AFTER_EXAM_PERIOD	6	7	4	2

Sistem koristi profile kao što su DEFAULT, FRESHMAN, WORKING_STUDENT i FINAL_YEAR, kao i akademske periode REGULAR_CLASSES, MIDTERM_WEEK, EXAM_PERIOD i AFTER_EXAM_PERIOD. Na osnovu tih vrijednosti generiše se odgovarajući ThresholdProfile.

ThresholdProfile sadrži pragove kao što su minimalan broj sati sna, prag visokog stresa, prag niske akademske efikasnosti, maksimalan broj propuštenih obaveza i pragovi za indikatore. Vrijednosti iz template-a ne predstavljaju konačnu procjenu rizika, već operative pragove koje pravila koriste pri formiranju izvedenih činjenica, kao što su ExhaustionIndicator, CynicismIndicator, ReducedEfficacyIndicator i CEP obrasci.

Na primjer, za isti dnevni unos sistem može dati različit rezultat u zavisnosti od akademskog perioda. U redovnoj nastavi unos može ostati LOW_RISK, dok u ispitnom roku isti unos može preći u MODERATE_RISK, jer EXAM_PERIOD koristi stroži prag za nisku akademsku efikasnost. Time se pokazuje da template-generated pravila direktno utiču na zaključivanje.

Ulazi u sistem

Glavni ulaz u sistem je **AssessmentRequest**. On sadrži studentId, profileType, academicPeriod i listu dnevnih unosa dailyCheckIns.

Na osnovu studentId, profileType i academicPeriod servis kreira StudentContext, koji se ubacuje u Drools radnu memoriju. StudentContext se koristi za izbor odgovarajućeg ThresholdProfile pravila.

Dnevni unosi se modeluju kroz DailyCheckInEvent. Jedan DailyCheckInEvent sadrži podatke o snu, stresu, umoru, motivaciji, koncentraciji, akademskoj efikasnosti, preopterećenosti, smislu studiranja, propuštenim obavezama, oporavku, podršci i coping strategiji.

Polja dnevnog unosa su:

studentId, timestamp, dayIndex, sleepHours, sleepQuality, fatigue, stress, motivation, concentration, efficacy, missedObligation, lowRecovery, supportScore, overload, studyMeaning i copingStrategy.

Dio podataka se modeluje kao event, jer su važni učestalost, redoslijed i vrijeme nastanka. U finalnoj implementaciji koriste se dva glavna event tipa: DailyCheckInEvent i ScoreSnapshotEvent.

DailyCheckInEvent predstavlja dnevni self-report unos studenta. ScoreSnapshotEvent predstavlja dnevno izvedene vrijednosti parcijalnih skorova i koristi se za detekciju negativnog trenda kroz više uzastopnih unosa.

Ako pojedinačni dnevni unos nema studentId, servis mu dodjeljuje studentId iz glavnog zahtjeva. Ako timestamp nije zadat, servis postavlja trenutni datum. Dnevni unosi se sortiraju po dayIndex, što je važno za detekciju trenda.

Izlazi iz sistema

Sistem daje klasifikaciju rizika, dominantne dimenzije, detektovane indikatore, preporuke i objašnjenje zaključka.

1. Procjena rizika

- LOW_RISK
- MODERATE_RISK
- HIGH_RISK
- SEVERE_RISK

Ovi elementi se korisniku prikazuju kroz finalni objekat **RiskAssessment**, koji objedinjuje nivo rizika, dominantnu dimenziju, detektovane indikatore, preporuke i objašnjenje.

2. Dominantna dimenzija rizika

Sistem vraća i dimenziju koja najviše doprinosi riziku:

- akademska iscrpljenost,
- cinizam / distanca prema studijama,
- smanjena akademska efikasnost,
- kombinovani obrazac.

3. Detektovani dokazi

Primjeri:

- kontinuiran loš san,
- hroničan umor,
- visok stres,
- pad motivacije,
- pad koncentracije,
- smanjena akademska efikasnost,
- odlaganje obaveza,
- nedovoljan oporavak poslije ispita,
- rizičan obrazac u ispitnom roku.

4. Preporuke

Sistem vraća preporuke u obliku enum vrijednosti. U trenutnoj implementaciji koriste se preporuke:

- REST_AND_RECOVERY,
- STUDY_PLAN_RESTRUCTURING,
- SEEK_ACADEMIC_SUPPORT,
- SEEK_COUNSELING_SUPPORT,
- MONITOR_NEXT_7_DAYS.

Ako je rizik umjeren, sistem najčešće preporučuje praćenje stanja u narednom periodu i odmor. Ako je rizik visok ili severe, sistem dodaje preporuke za restrukturiranje plana učenja, traženje akademske podrške i, kod najizraženijih obrazaca, razgovor sa mentorom, savjetnikom ili studentskim savjetovalištem.

5. Objašnjenje zaključka

Sistem prikazuje zbog kojih indikatora, obrazaca, faktora i pravila je određen rizik dodijeljen. Na primjer: “Rizik je označen kao HIGH/SEVERE jer su u posljednjih 7 dana detektovani kontinuiran loš san, visok prosječan stres, slab oporavak i ponavljano niska akademska efikasnost.”

Baza znanja

Baza znanja nije zasnovana na proizvoljno definisanim pravilima, već na dimenzijama koje se koriste u validiranim instrumentima za procjenu akademskog burnout-a. Osnovu čine tri

dimenzije: akademska iscrpljenost, cinizam/distanca prema studijama i smanjena akademska efikasnost. Ove dimenzije se pojavljuju u MBI-SS i SBI instrumentima, dok CBI-S daje dodatnu osnovu za procjenu intenziteta burnout simptoma kod studenata.

U sistemu se ove dimenzije koriste kao struktura za formiranje indikatora rizika. Na osnovu dnevnih unosa i događaja kroz vrijeme sistem računa parcijalne skorove:

- **ExhaustionScore** – skor akademske iscrpljenosti,
- **CynicismScore** – skor cinizma/distanciranja od studija,
- **EfficacyScore** – skor akademske efikasnosti.

Za razliku od ExhaustionScore i CynicismScore, kod kojih veća vrijednost označava veći rizik, kod EfficacyScore niža vrijednost označava veći rizik.

Svaki skor se računa na osnovu više ulaznih parametara, a ne na osnovu jednog podatka.

U sistemu se koriste sljedeći tipovi činjenica:

- **Score**: numeričke vrijednosti izvedene iz dnevnih unosa, npr. ExhaustionScore, CynicismScore i EfficacyScore.
- **ScoreAdjustment**: pomoćne činjenice koje predstavljaju pojedinačne doprinose skorovima. One se kasnije sabiraju pomoću accumulate funkcije.
- **Indicator**: zaključak da je određena dimenzija rizična, npr. ExhaustionIndicator, CynicismIndicator i ReducedEfficacyIndicator.
- **Pattern**: vremenski obrazac detektovan CEP pravilima, npr. SustainedPoorSleepPattern, SustainedStressPattern i AvoidancePattern.
- **Factor**: zaštitni ili pogoršavajući faktor, npr. ProtectiveSupportFactor, LowSupportRiskFactor i MaladaptiveCopingFactor.
- **Trend**: izvedena činjenica koja opisuje pogoršanje stanja kroz vrijeme, npr. NegativeTrend, kada se ExhaustionScore povećava ili EfficacyScore smanjuje kroz više uzastopnih unosa.
- **RiskAssessment**: finalna izvedena činjenica koja sadrži nivo rizika, dominantne dimenzije, aktivirane dokaze, preporuke i tekstualno objašnjenje zaključka.

Pored ovih činjenica, backward chaining koristi **EvidenceNode** i **EvidenceRelation**. EvidenceNode predstavlja dokaz koji postoji za konkretnog studenta, dok EvidenceRelation opisuje vezu između nižih i viših dokaza u evidence graph-u. Na osnovu tog grafa query hasAcademicBurnoutPattern(studentId) provjerava da li aktivirani dokazi zajedno podržavaju obrazac akademskog burnout-a.

Pored CEP obrazaca, sistem koristi i kombinovane obrasce rizika, kao što su BurnoutDevelopmentPattern i SevereRiskPattern, koji nastaju forward chaining pravilima kombinovanjem indikatora, vremenskih obrazaca i faktora rizika.

Skor akademske iscrpljenosti

U ovaj skor ulaze:

- broj sati sna,
- kvalitet sna,
- nivo umora,
- osjećaj preopterećenosti,
- nedovoljan oporavak poslije ispita ili roka,
- prosječan stres u posmatranom periodu.

Primjer pravila:

Ako student više dana ima loš san, visok umor i slab oporavak, sistem povećava **ExhaustionScore**. Ukoliko taj skor pređe definisani prag, ubacuje se činjenica **ExhaustionIndicator**.

Skor cinizma/distanciranja

U ovaj skor ulaze:

- pad motivacije,
- osjećaj da studije nemaju smisla,
- odlaganje obaveza,
- izbjegavanje učenja,
- propuštene vježbe, predavanja ili rokovi.

Primjer pravila:

Ako student više dana prijavljuje nisku motivaciju i nizak osjećaj smisla studiranja, uz odlaganje obaveza, sistem povećava **CynicismScore**. Ukoliko skor pređe definisani prag, ubacuje se činjenica **CynicismIndicator**.

Skor akademske efikasnosti

U ovaj skor ulaze subjektivna akademska efikasnost, koncentracija i propuštene obaveze.

Za razliku od **ExhaustionScore** i **CynicismScore**, kod kojih veća vrijednost označava veći rizik, kod **EfficacyScore** niža vrijednost označava veći rizik.

Primjer pravila:

Sistem kao osnovu uzima subjektivnu akademsku efikasnost koju student unosi. Ako student prijavljuje slabu koncentraciju ili propuštenu obavezu, **EfficacyScore** se dodatno smanjuje. Ukoliko skor padne ispod ili bude jednak pragu definisanom u **ThresholdProfile** činjenici, ubacuje se činjenica **ReducedEfficacyIndicator**.

Ovaj dio je povezan sa template pravilima, jer prag za nisku akademsku efikasnost može zavistiti od akademskog perioda. Na primjer, u ispitnom roku isti nivo efikasnosti može biti značajniji signal rizika nego u redovnoj nastavi.

Zaštitni i pogoršavajući faktori

Pored tri osnovna skora, sistem koristi i faktore koji mogu pojačati ili ublažiti procijenjeni rizik.

Ako student ima visok stres i nisku podršku, sistem ubacuje **LowSupportRiskFactor**.

Ako student ima visok stres i dominantno koristi izbjegavanje ili odlaganje, sistem ubacuje **MaladaptiveCopingFactor**.

Ako student ima povišen rizik, ali visoku socijalnu podršku i koristi aktivno rješavanje problema, sistem ubacuje **ProtectiveSupportFactor**.

Pravila za ukupnu procjenu rizika

Nakon formiranja indikatora, sistem kombinuje tri dimenzije:

- **ExhaustionIndicator + ReducedEfficacyIndicator → ModerateBurnoutRisk**
- **ExhaustionIndicator + CynicismIndicator → ModerateBurnoutRisk**
- **ExhaustionIndicator + CynicismIndicator + ReducedEfficacyIndicator → HighBurnoutRisk**
- **HighBurnoutRisk + SustainedStressPattern + SustainedPoorSleepPattern → BurnoutDevelopmentPattern**
- **BurnoutDevelopmentPattern + AvoidancePattern → SevereRiskPattern**
- **HighBurnoutRisk + LowSupportRiskFactor + MaladaptiveCopingFactor → SevereRiskPattern**
- **HighBurnoutRisk + ProtectiveSupportFactor → HighRiskWithSupportResources**
- **ModerateBurnoutRisk + ProtectiveSupportFactor → ModerateRiskWithProtectiveFactors**

- **HighBurnoutRisk + LowRecoveryPattern → SevereRiskPattern**
- **ModerateBurnoutRisk + RepeatedLowMotivationPattern + AvoidancePattern → HighBurnoutRisk**
- **ModerateBurnoutRisk + NegativeTrend → HighBurnoutRisk**
- **HighBurnoutRisk + NegativeTrend + LowRecoveryPattern → SevereRiskPattern**

Nakon određivanja najvišeg aktiviranog obrasca rizika, sistem formira finalnu činjenicu **RiskAssessment**. Na primjer:

SevereRiskPattern + dominantne dimenzije + aktivirani CEP obrasci → RiskAssessment(SEVERE_RISK, preporuke, objašnjenje)

HighRiskWithSupportResources → RiskAssessment(HIGH_RISK, preporuke, objašnjenje sa zaštitnim faktorima)

ModerateRiskWithProtectiveFactors → RiskAssessment(MODERATE_RISK, blaže preporuke, objašnjenje)

Ako se istovremeno aktiviraju zaštitni faktori i obrasci visokog ili severe rizika, sistem bira viši nivo rizika, dok se zaštitni faktori koriste za nijansiranje objašnjenja i preporuka.

NegativeTrend nije obavezan dokaz u backward chaining stablu, već dodatni vremenski obrazac koji pojačava nivo rizika kada se već pojavljuju indikatori burnout-a.

U pojednostavljenom obliku, dvije aktivirane dimenzije najčešće vode ka MODERATE_RISK, dok tri aktivirane dimenzije ili umjeren rizik pojačan negativnim trendom i obrascima izbjegavanja mogu voditi ka HIGH_RISK. SEVERE_RISK se formira kada se visok ili razvojni obrazac rizika dodatno pojača vremenskim obrascima, slabim oporavkom, izbjegavanjem obaveza, niskom podrškom ili maladaptivnim coping strategijama.

ModerateBurnoutRisk, HighBurnoutRisk, BurnoutDevelopmentPattern i SevereRiskPattern su izvedene činjenice nastale forward chaining pravilima i koriste se za formiranje RiskAssessment izlaza. HighBurnoutRisk može nastati kada su aktivirane sve tri osnovne dimenzije burnout modela, ali i kada je prethodno umjeren rizik pojačan dodatnim obrascima kao što su negativan trend, ponavljana niska motivacija ili izbjegavanje obaveza. BurnoutDevelopmentPattern označava da se visok rizik pojavljuje zajedno sa vremenskim obrascima kontinuiranog stresa i lošeg sna, dok SevereRiskPattern označava najizraženiji rizični obrazac koji vodi ka finalnoj procjeni SEVERE_RISK.

Backward chaining koristi evidence graph pristup. Izvedene činjenice se prevode u EvidenceNode, a EvidenceRelation opisuje kako pojedinačni dokazi podržavaju više pojmove kao što su CoreBurnoutEvidence, ChronicityEvidence i AcademicImpactEvidence. Query

hasAcademicBurnoutPattern(studentId) zatim provjerava da li aktivirani dokazi zajedno podržavaju obrazac akademskog burnout-a.

Konkretan primjer rezonovanja, korak po korak

Student A je u ispitnom roku i tokom više dana unosi podatke koji ukazuju na visok stres, loš san, pad motivacije i smanjenu akademsku efikasnost.

Dan	San	Stres	Motivacija	Koncentracija	Efikasnost	Obaveze
Ponedjeljak	5h	7	5	6	6	Ispunjene
Utorak	4h	8	5	4	5	Ispunjene
Srijeda	4.5h	9	3	3	4	Propuštene vježbe
Četvrtak	5h	8	4	5	4	Ispunjene
Petak	4h	9	2	2	3	Propušten rok
Subota	6h	7	2	3	4	Pokušaj odmora, slab oporavak
Nedjelja	5h	8	3	5	3	Odlaganje učenja

Prvi nivo zaključivanja formira osnovne činjenice:

- nizak broj sati sna povećava **ExhaustionScore**,
- visok umor i slab oporavak povećavaju **ExhaustionScore**,
- pad motivacije i odlaganje obaveza povećavaju **CynicismScore**,
- niska koncentracija i niska subjektivna akademska efikasnost smanjuju **EfficacyScore**.

Drugi nivo zaključivanja formira indikatore:

- visok **ExhaustionScore** → **ExhaustionIndicator**,
- visok **CynicismScore** → **CynicismIndicator**,
- nizak skor akademske efikasnosti → **ReducedEfficacyIndicator**.

CEP pravila zatim analiziraju događaje kroz vrijeme. Korišćenjem **accumulate** funkcije i vremenskog prozora od 7 dana sistem zaključuje da postoji **SustainedPoorSleepPattern**, jer se loš san javlja više puta u toku sedmice, kao i **SustainedStressPattern**, jer je prosječan nivo stresa visok u istom periodu.

Dodatno, zbog više dana niske motivacije i slabog oporavka, sistem formira **RepeatedLowMotivationPattern** i **LowRecoveryPattern**, što pojačava procjenu rizika.

Pošto student više dana prijavljuje nisku akademsku efikasnost, sistem formira i **AcademicGoalDeviationPattern**. Ovaj obrazac se zatim prevodi u EvidenceNode i preko EvidenceRelation učestvuje u dokazivanju akademskog uticaja obrasca.

Pošto se u prva tri dana posmatranog perioda vidi pad efikasnosti kroz uzastopne unose, sistem na osnovu **ScoreSnapshotEvent** događaja može formirati **NegativeTrend**, koji dodatno pojačava procjenu rizika.

Treći nivo zaključivanja kombinuje indikatore:

ExhaustionIndicator + CynicismIndicator + ReducedEfficacyIndicator → HighBurnoutRisk

Zatim se aktiviraju dodatna pravila nad vremenskim obrascima:

HighBurnoutRisk + SustainedStressPattern + SustainedPoorSleepPattern → BurnoutDevelopmentPattern

Pošto je detektovan i **LowRecoveryPattern**, rizik se dodatno pojačava:

HighBurnoutRisk + LowRecoveryPattern → SevereRiskPattern

Ako se potvrdi i **NegativeTrend**, odnosno pogoršanje efikasnosti ili iscrpljenosti kroz uzastopne unose, sistem dodatno potvrđuje *severe* obrazac:

HighBurnoutRisk + NegativeTrend + LowRecoveryPattern → SevereRiskPattern

Četvrti nivo zaključivanja koristi procijenjeni rizik i dominantne dimenzije za izbor preporuke i generisanje objašnjenja. Pošto su u severe scenariju aktivirane sve tri osnovne dimenzije, sistem dominantnu dimenziju opisuje kao kombinovani obrazac: akademska iscrpljenost, cinizam/distanca i smanjena akademska efikasnost. Na osnovu SevereRiskPattern činjenice sistem bira preporuke REST_AND_RECOVERY, STUDY_PLAN_RESTRUCTURING, SEEK_ACADEMIC_SUPPORT i SEEK_COUNSELING_SUPPORT.

Backward chaining se koristi kada korisnik ili savjetnik postavi pitanje:

hasAcademicBurnoutPattern(studentA)

Sistem tada ne traži nove ulazne podatke, već provjerava da li izvedeni dokazi iz radne memorije podržavaju cilj. Indikatori kao što su ExhaustionIndicator, CynicismIndicator i ReducedEfficacyIndicator, kao i CEP obrasci poput SustainedStressPattern, SustainedPoorSleepPattern, LowRecoveryPattern, AvoidancePattern i AcademicGoalDeviationPattern, prethodno su prevedeni u EvidenceNode činjenice.

Preko EvidenceRelation činjenica sistem zna koji dokazi podržavaju više pojmove u evidence graph-u. Rekurzivni query reachesEvidence provjerava da li konkretni dokazi direktno ili indirektno vode ka cilju AcademicBurnoutPattern. Ako su formirani CoreBurnoutEvidence, ChronicityEvidence i AcademicImpactEvidence, i ako preko EvidenceRelation hijerarhije svi podržavaju AcademicBurnoutPattern, query hasAcademicBurnoutPattern(studentA) vraća pozitivan rezultat.

Pošto su forward chaining pravila prethodno izvela SevereRiskPattern, a backward chaining query potvrđuje da aktivirani dokazi podržavaju obrazac akademskog burnout-a, konačna procjena sistema je **SEVERE_RISK**, uz **hasAcademicBurnoutPattern = true**.

Na osnovu **SevereRiskPattern**, dominantnih dimenzija i aktiviranih CEP obrazaca, sistem formira finalnu činjenicu **RiskAssessment** sa nivoom SEVERE_RISK, preporukama i objašnjenjem.

Konačan izlaz sistema (sadržaj **RiskAssessment** činjenice):

- Rizik: **SEVERE_RISK**
- Dominantne dimenzije: kombinovani obrazac: akademska iscrpljenost, cinizam/distanca i smanjena akademska efikasnost
- Objašnjenje: “Rizik je označen kao SEVERE_RISK jer su detektovane sve tri dimenzije akademskog burnout obrasca, uz kontinuiran loš san, visok prosječan stres, slab oporavak, pad motivacije i ponavljano nisku akademsku efikasnost.”
- Preporuke: REST_AND_RECOVERY, STUDY_PLAN_RESTRUCTURING, SEEK_ACADEMIC_SUPPORT, SEEK_COUNSELING_SUPPORT

Opis preporuke: “Preporučuje se smanjenje opterećenja, planiranje odmora nakon ispita, reorganizacija plana učenja i razgovor sa mentorom, savjetnikom ili studentskim savjetovalištem, posebno ako se obrazac nastavi.”

Ograničenja sistema

Sistem ne postavlja dijagnozu i ne smije se koristiti kao zamjena za stručnu pomoć. Akademski burnout je kompleksan fenomen, a podaci koje student unosi mogu biti subjektivni, nepotpuni ili

netačni. Sistem zato daje procjenu rizika i objašnjenje zaključka, a ne medicinski ili klinički zaključak.

Drugo ograničenje je to što se sistem zasniva na pravilima. To ga čini objašnjivim, ali znači da ne uči samostalno kao ML model. Pravila i pragove je potrebno održavati i prilagođavati u skladu sa literaturom, domenskim konsultacijama i rezultatima testiranja.

Numerički pragovi u sistemu predstavljaju operativne aproksimacije za potrebe implementacije ekspertskog sistema. Na primjer, pragovi za minimalan broj sati sna, visok stres ili broj propuštenih obaveza ne predstavljaju univerzalne kliničke granice, već konfigurabilne vrijednosti koje služe za demonstraciju zaključivanja i detekciju rizičnih obrazaca. Zbog toga se konačna procjena ne zasniva na jednom pragu, već na kombinaciji više indikatora, vremenskih obrazaca i zaštitnih/pogoršavajućih faktora.

Zaključak

Implementirani sistem predstavlja ekspertski sistem za rano prepoznavanje rizičnih obrazaca povezanih sa akademskim burnout-om kod studenata. Njegova glavna vrijednost je u tome što procjenu ne zasniva samo na jednokratnom upitniku, već na eksplicitnim pravilima, vremenskim obrascima i objašnjenju aktiviranih indikatora.

Literatura i izvori

- [1] [World Health Organization, “Burn-out an occupational phenomenon: International Classification of Diseases”](#)
- [2] [Schaufeli et al., “Maslach Burnout Inventory – Student Survey / MBI-SS,”](#) model akademskog burnout-a: iscrpljenost, cinizam i akademska efikasnost
- [3] [Salmela-Aro et al., “School Burnout Inventory \(SBI\): Reliability and Validity,”](#) dimenzije: iscrpljenost, cinizam i osjećaj neadekvatnosti
- [4] [Campos et al., “Copenhagen Burnout Inventory – Student Version \(CBI-S\),”](#) validacija studentske verzije CBI instrumenta
- [5] [Ye, Y., Huang, X., & Liu, Y. \(2021\). Social Support and Academic Burnout Among University Students: A Moderated Mediation Model. Psychology Research and Behavior Management, 14, 335–344](#)
- [6] [Waterhouse, P., & Samra, R. \(2025\). University Students' Coping Strategies to Manage Stress: A Scoping Review. Educational Review](#)

- [7] [Carmona-Halty, M., Alarcón-Castillo, K., Semir-González, C., Sepúlveda-Páez, G., & Schaufeli, W. B. \(2024\). Burnout Assessment Tool for Students \(BAT-S\): evidence of validity in a Chilean sample of undergraduate university students. Frontiers in Psychology](#)
- [8] [Romiaty, R. et al. Digital Innovation in Early Detection of Student Burnout: Development and Validation of the Android-Based Assessment Application BURNTES](#)